

9 abril 2026

$$Q^*(s, a) = \sum_{s' \in S} T(s, a, s') [r(s, a, s') + \gamma \max_{a' \in A(s')} Q^*(s', a')]$$

SARSA : on-policy
Q-Learning : off-policy

```
class PoliticaEGreedy(Politica):  
    def __init__(self, epsilon):  
        self.epsilon = epsilon  
    def call(self, Q, A): (estado y diccionario Q) acc legales  
        if random.random() < epsilon:  
            return random.choice(A)  
        return max(A, key=lambda a: Q[(s, a)])
```

```
def SARSA(modp, num_ep, num_it, alpha, tol, epsilon)  
    # modp: modelo, num_ep: episodios, num_it: iteraciones, alpha: tasa de aprendizaje, tol: tolerancia, epsilon: tolerancia
```

$\pi = \text{PoliticaEGreedy}(\epsilon)$

$Q = \{(\text{tuple}(s), \text{tuple}(a)) : \emptyset \text{ for } s \text{ in } S \text{ for } a \text{ in } \text{mall. acciones legales}(s)\}$

```
for _ in range(num_ep):
```

$err = 0$

$s = \text{mall. estado inicial}()$

$a = \pi(s, \text{mall. acciones legales}(s), Q)$

```
for _ in range(num_it):
```

$s' = \text{mall. sucesor}(s, a)$

$r = \text{mall. recompensa}(s, a, s')$

9 abril 2026

$a' = \pi(s', \text{mell. acciones-legal}(s'))$

$q = r + \text{mell. } \gamma * Q[(s', a')]$

$\text{err} = \max(\text{err}, \text{abs}(Q[(s, a)] - q))$

$s, a = s', a'$

if $\text{mell. terminal}(s): \rightarrow Q[(s, a)]$

break

$+ = \alpha * (q - Q[(s, a)])$

if $\text{err} < \text{tol}:$

break

return Q .

on-policy primero- decide la nueva acción.
Estamos aprendiendo sobre lo que el entorno
Como inducción. En función de acciones
se genera el peso.

def Q-Learning(mell, num-ep, num-it, α , tol, ϵ

$\pi = \text{Política } \epsilon \text{ Greedy}(\epsilon)$

$Q = \{ (s, a) \text{ for } s \text{ in mell. } s \text{ for } a \text{ in mell. acciones-legal}(s) \}$

for in range(num-ep):

err = 0

$s = \text{mell. estado-inicial}()$

for in range(num-it):

$a = \pi(s, \text{mell. acciones-legal}(s, a))$

$s' = \text{mell. sucesor}(s, a)$

$r = \text{mell. recompensa}(s, a, s')$

$q = r + \text{mell. } \gamma * \max_{a' \text{ in mell. acciones-legal}(s')} (Q[(s', a')])$

$\text{err} = \max(\text{err}, \text{abs}(q - Q[(s, a)]))$

$Q[(s, a)] + = \alpha * (q - Q[(s, a)])$

$s = s'$

if $\text{mell. terminal}(s):$

break

9 abril 2026

it em < to | -

break

return Q -

- Métodos tabulares