

Agente reactivo

f_A es desconocido

$$P \rightarrow f_A(P) \rightarrow a; f_A : X \rightarrow y$$

espacio espacio
de entrada de salida

tipicamente X es \mathbb{R}^n

$$X = \mathbb{R}^n$$

$$x = (x_1, \dots, x_n) \in \mathbb{R}^n$$

Si $y = \mathbb{R}$ yo le doy algo x me devuelve un numero. REGRESION.

Si $y = \{-1, 1\}$ entonces se le conoce como clasificación binaria

Si $y = \{c_1, c_2, \dots, c_k\}$ se le conoce como clasificación en varias clases o multiclase.

Recordamos que f es desconocida. ¿Cómo la podemos encontrar? Vamos a decir que tiene un conjunto de datos

$\{x^{(1)}, x^{(2)}, \dots, x^{(n)}\}$ una muestra de X .

Esto es una muestra de un muestreo desorganizado.

(Datos) $D = \{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(n)}, y^{(n)})\}$
donde $y^{(i)} = f_A(x^{(i)}) + e$ Variable aleatoria
error de dist. desconocida

mis datos pueden tener errores! El problema entonces es encontrar una función $h^* : X \rightarrow y$ (h^* es la mejor función posible (óptima) tal que $h^* \approx f_A$)

20 Enero 2026

¿Cómo sabemos que es h^* ? $H \subseteq \mathcal{H}$ (hipótesis posibles)

$\mathcal{H} = \{h_\alpha / h_\alpha : \mathbb{R} \rightarrow \mathbb{R} \text{ donde } h_\alpha(x) = \alpha x, \forall \alpha \in \mathbb{R}\}$

$X = [X_1 \text{ (INGRESO HENSAU)}, X_2 \text{ (DEUDA)}, X_3 \text{ (PAGA A TIEMPO)}, X_4 \text{ (OTRA CREDITOS)}, X_5 \text{ (VALOR)}, X_6 \text{ (PROPIEDADES)}, X_7 \text{ (EDAD)}, X_8 \text{ (ESTADO CIVIL)}, X_9 \text{ (SI TIENEN HIJO(S)}, X_{10}, \dots, X_n \text{ (GENERO)}, X_{12} \text{ (CERCI)}]$

Yo quiero una función que diga si le damos crédito:

$x^{(1)} \in \mathbb{R}^{12}$	$x^{(1)} \dots x^{(n)}$	$x^{(1)} \dots x^{(n)}$	$\begin{cases} \text{Si} \\ \text{No} \end{cases}$	$\begin{cases} \$ \\ \$\$ \end{cases}$

- Recogiendo datos

- Entrenar un modelo

- Programar que la computadora resuelva un problema sin programarlo explícitamente

$x_i^{(1)} \dots x_i^{(n)}$	$x_i^{(1)} \dots x_i^{(n)}$	$\begin{cases} \text{Si/No} \end{cases}$	$\begin{cases} \$ \\ \$\$ \end{cases}$

clasificación Regresión
clase binaria (Clasificación)

Mi función $h: X \times \Theta \rightarrow Y$

$$h_\theta: (x^{(i)}, \Theta) \rightarrow \hat{y}^{(i)} \quad \{x^{(i)} \text{ y parámetros}\}$$

$$h_\theta(x^{(i)}) = \hat{y}^{(i)}$$

Si Θ es un valor de parámetros fijo

$h_\theta: X \rightarrow Y$ Encuentra la mejor función es encontrar el mejor vector de parámetros. Estos vectores se presentan abajo.

$$h(x) = \sum_{i=1}^T w_i x^i + w_0 \leftarrow \text{Esto es un polinomio}$$

Asumiendo que $x^i \in \mathbb{R}$

Una $\mathbb{R} \rightarrow \mathbb{R}$ una regresión, un polinomio, grado T

$$w = (w_0, w_1, \dots, w_T) \in \mathbb{R}^{T+1}, \hat{y} = w_0 + w$$

Análisis de algoritmos

21 de enero '26

Eficiencia = $f(n)$ encontrar solución en menor tiempo posible o con menor uso de memoria

subjetivo:

objetivo.

Simplicidad

Run time efficiency

Claridad

Eficiencia en utilización de memoria

(diseñado) para datos esperados

Algoritmos de ordenamiento

1 2 3 4 5 6

- Programar el algoritmo

5 1 3 2 4 6

- Medir el tiempo de ejecución de

6 5 4 3 2 1

una implementación particular en una computadora específica y para un conjunto seleccionado de datos.

- una implementación particular en

- Popular y útil - RISC y CISC

22 enero 2026

Hipótesis

1. $f: X \rightarrow y$, existe y es desconocida

2. Tengo $\{x^{(1)}, \dots, x^{(n)}\} \subset X$ una muestra de mis datos con distribución desconocida.

3. $D = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$ donde

$y^{(i)} = f(x^{(i)}) + e^{(i)}$ donde $e^{(i)}$ son variables aleatorias

4. Tenemos una función "parametrizada"

$h: X \times \Theta \rightarrow y$, típicamente $\Theta = \mathbb{R}^r$

5. para un valor específico de θ ,


$h_\theta: X \rightarrow y$

6. h_θ es el conjunto de hipótesis

- h dice que método estoy usando

El aprendizaje supervisado consiste en encontrar $h^* \in H$ tal que $h^* \approx f$

$\hat{y} \rightarrow$ estimada



$L: y \times y \rightarrow \mathbb{R}$ función de pérdida

$$L(y, \hat{y}) = L(f(x), h^*(x))$$

$$L(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2 \quad y \in \mathbb{R}$$

Esta es la del error cuadrado.

$= |y - \hat{y}|$, $|y - \hat{y}|$ cuando $y > 0$, error absoluto porcentual.

$$L(y, \hat{y}) = \begin{cases} 0 & \text{si } y = \hat{y} \\ 1 & \text{si } y \neq \hat{y} \quad y \in \{-1, 1\} \end{cases}$$

22 enero 2026

Hipótesis

1. $f: X \rightarrow y$ existe y es desconocida
2. tengo $\{x^{(1)}, \dots, x^{(n)}\} \subset X$ una muestra de mis datos con distribución desconocida
3. $D = \{(x^{(1)}, y^{(1)}), \dots, (x^{(n)}, y^{(n)})\}$ donde

$y^{(i)} = f(x^{(i)}) + e^{(i)}$ donde $e^{(i)}$ son variables aleatorias

4. Tenemos una función "parametrizada"

$$h: X \times \Theta \rightarrow y, \text{ típicamente } \Theta = \mathbb{R}^r$$

5. para un valor específico de θ ,


$$h_\theta: X \rightarrow y$$

6. h_θ es el conjunto de hipótesis

• h dice que método estoy usando

El aprendizaje supervisado consiste en encontrar $h^* \in H$ tal que $h^* \approx f$

$\hat{y} - \text{estimada}$



$$L: y \times y \rightarrow \mathbb{R} \text{ función pérdida}$$

$$L(y, \hat{y}) = L(f(x), h^*(x))$$

$$L(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2 \quad y \in \mathbb{R}$$

Esta es la del error cuadrático.

$= |y - \hat{y}|$, $|y - \hat{y}|$ cuando $y > 0$, error

y

absoluto parcial.

$$L(y, \hat{y}) = \begin{cases} 0 & \text{si } y = \hat{y} \\ 1 & \text{si } y \neq \hat{y} \end{cases}$$

22 enero 2016

$$E_{out}(h^*) = E_{x \sim X} [L(L(x), h^*(x))]$$

$$f \approx h^* \text{ si } E_{out}(h^*) \approx 0$$

Error fuera de muestra porque lo calculamos con todos los datos.

↓ Error en muestra solo se puede calcular con datos de aprendizaje

$$\bar{E}_{in}(h^*) = \frac{1}{M} \sum_{i=1}^M L(y^{(i)}, h^*(x^{(i)}))$$

(suponemos que
todos los datos
con igual de
probabilidad)

$$f \approx h^* \text{ si } \bar{E}_{in}(h^*) \approx 0$$

$$\rightarrow \bar{E}_{in}(h^*) \approx E_{out}(h^*)$$

> Regresión lineal y logística. Redes neuronales

> Método de árboles de decisión

• MSE, med absolute error (MAE), MAPE

> DUDA:

Θ = Vector de parámetros

$$h_\Theta(x) = w_1 x_1 + w_2 x_2 + w_3 x_3 + b$$

$$\Theta = (w_1, w_2, w_3, b) \in \mathbb{R}^4$$

22 enero 2026

DESIGUALDAD DE Hoeffding $P\{ |E_{out}(h^*) - E_{in}(h^*) | > \varepsilon \} \leq e^{-\frac{2\varepsilon^2 M}{e}}$

donde M es el tamaño de la muestra

la probabilidad que no se parezcan

Si yo tengo poco datos no se puede decir nada acerca del aprendizaje

¿Cómo sabemos cuántos datos necesitamos?

DVC (dimension, vechnik - chernovensky)

$DVC(H) \approx \#$ de parámetros independientes

El aprendizaje es posible si $10 * DVC(H) \ll M$

$\hookrightarrow E_{in}(h^*) \approx E_{out}(h^*)$

23 enero 2026

- Necesitamos tener 10 veces más datos que parámetros independientes

atributos

nros x nro ob.

anexo de
cabos

$$\begin{array}{c} \text{nos x nro ob.} \\ \text{anexo de} \\ \text{cabos} \end{array} \quad \begin{array}{cccccc} a_1 & a_2 & \dots & a_n & y \end{array}$$

$\begin{array}{c} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{array} \rightarrow \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(n)} & x_2^{(n)} & \dots & x_n^{(n)} \end{bmatrix} \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$

$x^{(m,n)}$
matriz

$y^{(m,1)}$
y es vector

$$x^{(i)} \in \mathbb{R}^n ; y^{(i)} \in \mathbb{R}$$

conjunto de hipótesis $h_{\theta}(x)$

$$h_{\theta}(x) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

Función lineal?

$$h_{\theta}(x) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b = \sum_{j=1}^n w_j x_j + b$$

$$= \mathbf{w}^T \mathbf{x} + b = \mathbf{x}^T \mathbf{w} + b$$

$$\text{Si } \mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$$

$$\mathbf{w} = (w_1, \dots, w_n) \in \mathbb{R}^n$$

$$\Theta = (w_1, \dots, w_n, b) \in \mathbb{R}^{n+1}$$

Aprendizaje implica que $E_{in}(h^*) \approx E_{out}(h^*)$

> Tener suficientes datos

> Que $E_{in}(h^*) \approx 0$

> Quisiéramos que $h^* \in \arg \min_{h \in H} E_{in}(h)$

23 enero 2026

$$h^* = \arg \min_{h \in H} E_{\text{in}}(h) \leftrightarrow \hat{\theta}^* = w^*, b^* = \arg \min_{w \in \mathbb{R}^n, b \in \mathbb{R}} E_{\text{in}}(h_{w,b})$$

> b es sesgo aquí

> Encontrar mejores argumentos

mejor w , mejor b

$$w^*, b^* = \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{M} \sum_{i=1}^M \frac{1}{2} (y^{(i)} - h_{w,b}(x^{(i)}))^2$$

error cuadrático promedio o mean square error

24-87

$$X^{(i)} = y^{(i)}$$

$$w^*, b^* = \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{M} \sum_{i=1}^M \frac{1}{2} (y^{(i)} - X^{(i)\top} w - b)^2$$

$$= \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{2M} \left[(y^{(1)} - X^{(1)\top} w - b) \right. \\ \left. \dots (y^{(m)} - X^{(m)\top} w - b) \right]$$

Entonces $\times \left[\begin{array}{c} y^{(1)} - X^{(1)\top} w - b \\ y^{(2)} - X^{(2)\top} w - b \\ \vdots \\ y^{(m)} - X^{(m)\top} w - b \end{array} \right]$

$$\begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix} - \begin{bmatrix} X^{(1)\top} \\ X^{(2)\top} \\ \vdots \\ X^{(m)\top} \end{bmatrix} w = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} b$$

y X b

23 enero 2020

entonces

$$= \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{2M} [y - x^T w - b]^T [y - x^T w - b]$$

33:19

$$= \arg \min_{\theta \in \mathbb{R}^{n+1}} \frac{1}{2M} [y - [x, 1]^T \theta]^T [y - [x, 1]^T \theta]$$

- mínimo respecto a θ donde θ es un vector

$$\Rightarrow \text{DEMO } 35x^5 + 4x + 3$$

Derivadas e igualas a 0

$$3 \cdot 35x^2 + 4 = 0$$

$$x = \pm \sqrt{\frac{-4}{3 \cdot 35}}$$

$$f(x_1, \dots, x_n)$$

$$f(x) \quad x \in \mathbb{R}^n, f: \mathbb{R}^n \rightarrow \mathbb{R}$$

$$\begin{array}{c} \nabla f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix} \end{array}$$

Gradiente

- El mínimo se encuentra cuando el gradiente sea 0

- Calculamos gradientes e igualamos a 0.

partidas parciales

23 enero 2020

entonces

$$= \arg \min_{\substack{w \in \mathbb{R}^n \\ b \in \mathbb{R}}} \frac{1}{2M} [y - x^T w - b]^T [y - x^T w - b]$$

33:19

$$= \arg \min_{\theta \in \mathbb{R}^{n+1}} \frac{1}{2M} [y - [x, 1]^T \theta]^T [y - [x, 1]^T \theta]$$

- mínimo respecto a θ donde θ es un vector

$$\rightarrow \text{DEMO } 35x^2 + 4x + 3$$

Derivas e igualas a 0

$$3 \cdot 35x^2 + 4 = 0$$

$$x = \pm \sqrt{\frac{-4}{3 \cdot 35}}$$

$$f(x_1, \dots, x_n)$$

$f(x) \quad x \in \mathbb{R}^n, f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$\nabla_x f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

Gradiente

- El mínimo se encuentra cuando el gradiente sea 0.

- Calculamos gradiente e igualamos a 0.

derivadas parciales

23 enero 2026

$$= \arg \min_{\theta \in \mathbb{R}^{n+1}} \frac{1}{2M} [y - [x_e] \theta]^T [y - [x_e] \theta]$$

$$[y - [x_e] \theta]^T [y - [x_e] \theta] \quad [x_e]$$

$$\frac{\partial V(x)}{\partial x} = \frac{\partial V(x)}{\partial x} ; \frac{\partial (y - kx)^2}{\partial x} = -2(y - kx)k$$

entonces

$$\frac{\partial}{\partial \theta} \left[\frac{1}{2M} [y - [x_e] \theta]^T [y - [x_e] \theta] \right] = \vec{0}$$

$$[x_e]^T [y - [x_e] \theta] = \vec{0}$$

$$[x_e]^T y - [x_e]^T [x_e] \theta = \vec{0}$$

$$[x_e]^T [x_e] \theta = [x_e]^T y$$

$$\theta = \underbrace{[x_e]^T [x_e]}^{-1} [x_e]^T y$$

metodo de minimos cuadrados

pseudoinversa de penrose ($[x_e]$)

o pinv($[x_e]$) \rightarrow numpy, en python