

26 enero 2026

$$b_{k+1} \leftarrow b_k - \eta \frac{\partial \text{Ein}(\theta_k, b_k)}{\partial b}$$

$$w_{j,k+1} \leftarrow w_{j,k} - \eta \frac{\partial \text{Ein}(\theta_k, b_k)}{\partial w_j}$$

27 enero 2026

$$\theta_{k+1} \leftarrow \theta_k - \eta \nabla f(\theta_k)$$

$$h_\theta(x) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

$$= [x, 1] \begin{bmatrix} w \\ b \end{bmatrix} = [x^T, 1] \theta$$

* - mejor

$$\theta^* = w^*, b^* = \arg \min_{\theta \in \mathbb{R}^{n+1}} \frac{1}{2M} \sum_{i=1}^M (y^{(i)} - [x^T, 1] \theta)^2$$

Para w_j

$$\frac{\partial \text{Ein}(\theta)}{\partial w_j} = \frac{1}{2M} \sum_{i=1}^M -2(y^{(i)} - \hat{y}^{(i)}) \cdot x_j^{(i)}$$

$$\frac{\partial \text{Ein}(\theta)}{\partial b} = \frac{1}{2M} \sum_{i=1}^M -2(y^{(i)} - \hat{y}^{(i)}).$$

desc. grad. en muestra

$$\nabla \text{Ein}(\theta_k) = \begin{pmatrix} \frac{1}{M} \sum_{i=1}^M -(y^{(i)} - \hat{y}^{(i)}) x_1^{(i)} \\ \frac{1}{M} \sum_{i=1}^M -(y^{(i)} - \hat{y}^{(i)}) x_2^{(i)} \end{pmatrix}$$

Podemos:

sacar

$$-\frac{1}{M} \begin{pmatrix} \sum_{i=1}^M -(y^{(i)} - \hat{y}^{(i)}) x_n^{(i)} \\ \sum_{i=1}^M -(y^{(i)} - \hat{y}^{(i)}) \end{pmatrix}$$

27 enero 2026

continuación

$$= -\frac{1}{M} \begin{bmatrix} X_1^{(1)} & X_1^{(2)} & \dots & X_1^{(m)} \\ X_2^{(1)} & X_2^{(2)} & \dots & X_2^{(m)} \\ \vdots & & & \\ X_n^{(1)} & X_n^{(2)} & \dots & X_n^{(m)} \\ 1 & 1 & \dots & 1 \end{bmatrix}_{(n+1, m)}^T \begin{bmatrix} Y - Xe\theta \\ Y^{(1)} - \hat{Y}^{(1)} \\ Y^{(2)} - \hat{Y}^{(2)} \\ \vdots \\ Y^{(m)} - \hat{Y}^{(m)} \end{bmatrix}_{(m, 1)} \rightarrow Xw + b$$

$$\theta \leftarrow \theta - \eta \nabla E_{in}(\theta)$$

$$\theta \leftarrow \theta + \frac{\eta}{M} \underbrace{Xe^T(Y - Xe\theta)}$$

24:00 Programa en Python

- Necesito un programa que aprende y uno que predice.
(descenso gradiente de una lineal con $Xw + b$)
epochs: de $\text{dg_lin}(X, Y, w_0, b_0, lr, \text{max_epochs}, \epsilon_tol)$:
iteraciones

```
w = w0.copy() # las cond. iniciales
b = b0.copy() # no las modifiquemos
hist = [] # historial
for _ in range(max_epochs):
    y_est = X @ w + b # @ es mult. matricial
    Err = y - y_est
    hist.append(np.square(Err).mean())

```

Y e Y ya deben existir
X.shape = [m, n], y.shape = [m, 1]
w = np.zeros(X.shape[-1]) x.shape[-1] = n
b = 0
w_n, b_n, hist = dg_lin(X, Y, w, b, 0.1, 50,
-1e-4)

$-n$
es now

27 enero 2026

$M = X.shape$
[0]

¿es aprendizaje suficiente? No. lo vuelve a llamar.
continua python.

$y = stage$
 \bar{m}

derivable
de b

$\bar{d} \cdot b$

$$\text{grad_w} = -(1/M) X.T @ Err$$

$$d \cdot b = Err.\text{mean}()$$

$$w' = lr \cdot \text{grad_w}$$

$$b' = lr \cdot d \cdot b$$

if np.abs(grad_w).max() < e.tol:

break

return w, b, hist

29 enero 2026

Convertir de discreto a continuo

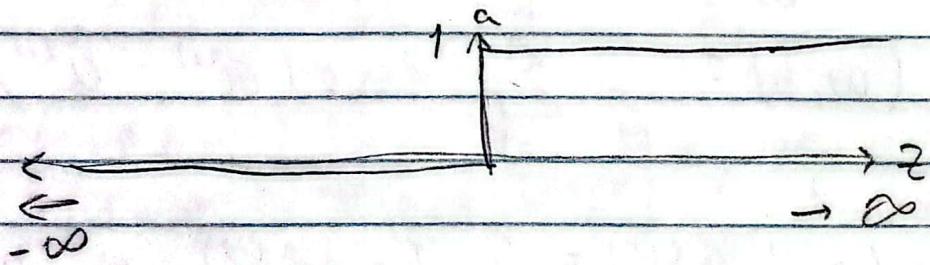
$$\Pr(Y=1 | X=x; \theta) = \hat{a} \quad \begin{array}{l} \text{saldado de neurona} \\ (\text{activación}) \end{array}$$

$$\hat{y} = \begin{cases} 1 & \text{si } a > \text{umbral} \\ -1 & \text{en otro caso} \end{cases} \quad \begin{array}{l} \text{- usamos umbral para} \\ \text{poner un mínimo aceptable} \end{array}$$

\rightarrow Máximo a posteriori $\rightarrow h=0.5$

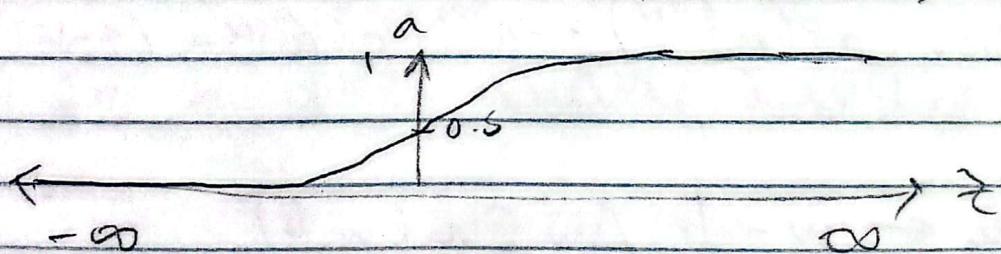
$$\hat{a} = f(w_1x_1 + w_2x_2 + \dots + w_nx_n + b)$$

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b = X^T w + b = X e^T \theta$$



Si z es negativo, $a = -1$, si es positivo,

1. \rightarrow Delta de dira, función de pulso



$$\sigma(z) = \frac{1}{1+e^{-z}} \quad ; \text{ sigmoid, función logística}$$

$$\hat{a} = \Pr(Y=1 | X=x; \theta) = \sigma(w^T x + b)$$

\rightarrow Regresión logística

$$\left[\begin{array}{c|c|c} x_1^{(1)} & \dots & x_n^{(1)} \\ x_1^{(2)} & \dots & x_n^{(2)} \\ \vdots & & \vdots \\ x_1^{(m)} & \dots & x_n^{(m)} \end{array} \right] \quad \left[\begin{array}{c} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{array} \right] \quad \left[\begin{array}{c} a^{(1)} \\ a^{(2)} \\ \vdots \\ a^{(m)} \end{array} \right]$$

X

Y

A

(probabilidad)

$$y^{(i)} \in \{-1, 1\}$$

pérdida
de info

$$Ein(w, b) = \frac{1}{M} \sum_{i=1}^M \text{loss}(a^{(i)}, \hat{a}^{(i)})$$

Proposición 1

$$\text{Loss}(a^{(i)}, \hat{a}^{(i)}) = \begin{cases} -\log(\hat{a}^{(i)}) & \text{si } a^{(i)} = 1 \\ -\log(1 - \hat{a}^{(i)}) & \text{si } a^{(i)} = 0 \end{cases}$$

$$\text{loss}(a^{(i)}, \hat{a}^{(i)}) = -a^{(i)} \log(\hat{a}^{(i)}) - (1 - a^{(i)}) \log(1 - \hat{a}^{(i)})$$

Función de pérdida

$$w \leftarrow w - lr \Delta w Ein(w, b)$$

$$b \leftarrow b - lr \frac{\partial}{\partial b} Ein(w, b)$$

Calcular der. parcial respecto a w_j

$$\frac{\partial}{\partial w_j} Ein(w, b) = \frac{1}{M} \sum_{i=1}^M$$

$$\log(\hat{a}^{(i)}) - (1 - a^{(i)}) \log(1 - \hat{a}^{(i)})$$

$$\text{donde } \hat{a}^{(i)} = \frac{1}{1 + e^{-z^{(i)}}}, \text{ y } z^{(i)} = w_1 x_1^{(i)}$$

$$+ \dots + w_n x_n^{(i)} + b$$

29 enero 2026

$$= \frac{1}{M} \sum_{i=1}^m -a^{(ii)} \frac{\partial a^{(ii)}}{\partial w_j} = \left(\frac{1-a^{(ii)}}{1+a^{(ii)}} \right) \frac{\partial a^{(ii)}}{\partial w_j}$$

$$\frac{d \log(V(x))}{V(x) \frac{d}{dx} V(x)} \frac{\partial a^{(ii)}}{\partial w_j} = \frac{2}{\partial w_j} \frac{1}{1+e^{-z^{(ii)}}}$$

$$= \frac{2}{2 z^{(ii)}} \frac{1}{1+e^{-z^{(ii)}}} \frac{\partial z^{(ii)}}{\partial w_j} = \frac{2}{2 z^{(ii)}} \frac{(1+e^{-z^{(ii)}})^{-1} 2 z^{(ii)}}{\partial w_j}$$

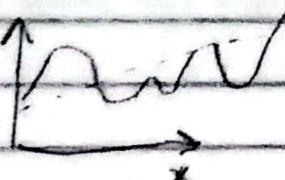
$$= (1+e^{-z^{(ii)}})^{-2} e^{-z^{(ii)}} x_j^{(ii)}$$

$$= \left(\frac{1+e^{-z^{(ii)}}}{(1+e^{-z^{(ii)}})^2} - \frac{1}{(1+e^{-z^{(ii)}})^2} \right) x_j^{(ii)}$$

$$= \left(\frac{1}{1+e^{-z^{(ii)}}} - \frac{1}{1+e^{-z^{(ii)}}} \right) x_j^{(ii)}$$

$$\downarrow \\ = (\hat{a}^{(ii)} - \hat{a}^{(ii)2}) = \hat{a}^{(ii)} (1 - \hat{a}^{(ii)}) x_j^{(ii)}$$

30 enero 2026

1  - Habría mucho error con
regresión lineal

$\phi: \mathbb{R}^n \rightarrow \mathbb{R}^{n'}$ - función generadora de
características

$$x \in \mathbb{R} \quad x' = \phi(x) = (x, x^2, x^3, x^4)$$

$$x' = \phi(x) = (\phi_1(x), \phi_2(x), \phi_3(x), \dots, \phi_n(x))$$

> Expansión polinomial

$$\begin{aligned} x &= (x_1, x_2), \quad q(x) = (x_1, x_2, x_1^2, x_1, x_2, x_2^2) \\ \phi(x) &= (x_1, x_2, x_1^2, x_1, x_2, x_2^2, x_3^3, x_3^2 x_2, \\ &\quad x_1, x_2, x_2^3) \end{aligned}$$

$$x = (x_1, x_2, x_3, x_4) \quad \text{Sólo 2do orden}$$

$$\phi(x) = (x_1, x_2, x_3, x_4, x_1^2, x_1 x_2, x_1 x_3, x_1 x_4, x_2^2, \\ x_2 x_3, x_2 x_4, x_3^3, x_3 x_4, x_4^2)$$

$H = \{h\}$ tal que

$$\begin{aligned} > h(x) &= w_1 x_1 + w_2 x_2 + w_3 x_3^3 + w_4 x_4^4 + w_5 x_5^5 \\ &\quad + w_6 x_1^6 + w_7 x_1^7 + w_8 x_1^8 + b \end{aligned}$$

> esto es bajo $w_j = 0 \quad \text{si } j \geq 3 \leftarrow$ restricciones
lineales

$$\begin{aligned} > h(x) &= w_1 x_1 + w_2 x_2 + b \end{aligned}$$

30 de enero 2026

> Las restricciones duras quieren ser excesivas para este tipo de aplicaciones

$$h(x) = w^T \phi(x) + b \quad w, \phi(x) \in \mathbb{R}^n, b \in \mathbb{R}$$

bajo $w_j = 0$ para $j \geq k$

Dim b_c es k porque es $k-1+1$ (por la b)

> y si cambiamos a restricciones suaves?

$$h(x) = w^T \phi(x) + b \quad w, \phi(x) \in \mathbb{R}^n, b \in \mathbb{R}$$

bajo $\sum_{j=1}^n w_j^2 \leq c$ producto punto de $w^T x w$

$w^T w \leq c$

> \sqrt{c} es el radio

> La norma de un vector es adonde llega

$$\|w\|_2 = \sqrt{w^T w} \quad \leftarrow L_2 \text{ norma 2}$$

$$\|w\|_1 = \sum_{j=1}^n |w_j| \quad \leftarrow L_1 \text{ (cuando solo puedes hacer 1 movimiento)}$$



A esto se le llama regularización.

> Calculo la dimensión b_c y si tenemos menos datos regularizamos.

30 enero 2026

Regularización lineal

N: w y b óptima que minimice error bajo cierta restricción.

5.02.2026

Tenemos el error

círculo

