

3 feb 2026

$$\begin{aligned}\frac{\partial \text{Ein}(w, b)}{\partial w_j} &= \frac{1}{M} \sum_{i=1}^m -(\hat{a}^{(i)} - \hat{a}^{(i)}) x_j^{(i)} \\ &= \frac{1}{M} \sum_{i=1}^m \left(-\frac{a^{(i)}}{\hat{a}^{(i)}} + \frac{1-a^{(i)}}{1-\hat{a}^{(i)}} \right) (\hat{a}^{(i)} - \hat{a}^{(i)}) x_j^{(i)} \\ \frac{\partial \text{Ein}(w, b)}{\partial w_j} &= \frac{\partial}{\partial w_j} \frac{1}{M} \sum_{i=1}^m \left[\frac{a^{(i)} / \ln(\hat{a}^{(i)}) - (1-a^{(i)})}{\ln(1-\hat{a}^{(i)})} \right] \\ &= \frac{1}{M} \sum_{i=1}^m -\frac{a^{(i)}}{\hat{a}^{(i)}} \frac{\frac{2\hat{a}^{(i)}}{2w_j} + \frac{1-a^{(i)}}{1-\hat{a}^{(i)}}}{\frac{2\hat{a}^{(i)}}{2w_j}} \\ &= \frac{1}{M} \sum_{i=1}^m \left[a^{(i)}(1-\hat{a}^{(i)}) + (1-a^{(i)})\hat{a}^{(i)} \right] x_j^{(i)} \\ &= \frac{1}{M} \sum_{i=1}^m \left[-a^{(i)} + a^{(i)} \cancel{\hat{a}^{(i)}} + \hat{a}^{(i)} - a^{(i)} \cancel{\hat{a}^{(i)}} \right] x_j^{(i)} \\ &= -\frac{1}{M} \sum_{i=1}^m (\hat{a}^{(i)} - \hat{a}^{(i)}) x_j^{(i)}\end{aligned}$$

3 Feb 2026

$$w \leftarrow w - lr \times^T (A \cdot \hat{A})$$

$$b \leftarrow b - lr \frac{1}{M} \sum_{i=1}^n (a^{(i)} - \hat{a}^{(i)})$$

Regularización

Multiplicador de la Grange

$$\geq w_{reg}, b_{reg} = \arg \min [E_{in}(w, b) + \frac{\lambda}{M} \sum_{j=1}^n w_j^2]$$

C tiene que ser ≥ 0

Podemos agregarle esto y se pone regular cualquier problema.

$\lambda = 0$ no regulariza

$\lambda \Rightarrow$ factor de regularización

$$\frac{\partial}{\partial w_j} \left[E_{in}(w, b) + \frac{\lambda}{M} \sum_{j=1}^n w_j^2 \right]$$

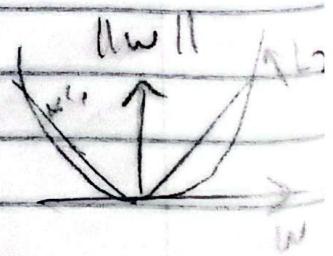
$$= -\frac{1}{M} \sum_{j=1}^n (a^{(j)} - \hat{a}^{(j)}) x_j^{(j)} + \underbrace{\frac{2\lambda}{M} w_j}_{\text{regularización}}$$

$$w^*_{reg}, b^*_{reg} = \arg \min [E_{in}(w, b)$$

$$+ \frac{\lambda}{M} \text{regu}(w)]$$

$$\text{regu}(w) \rightarrow \sum_{j=1}^n w_j^2 = \|w\|_2^2$$

$$\sum_{j=1}^n |w_j| = \|w\|_1$$



3 feb

reg. lineal + $\xrightarrow{\text{L}_1}$ Lasso Ridge
 $\xrightarrow{\text{L}_1 + \text{L}_2}$ ElasticNet

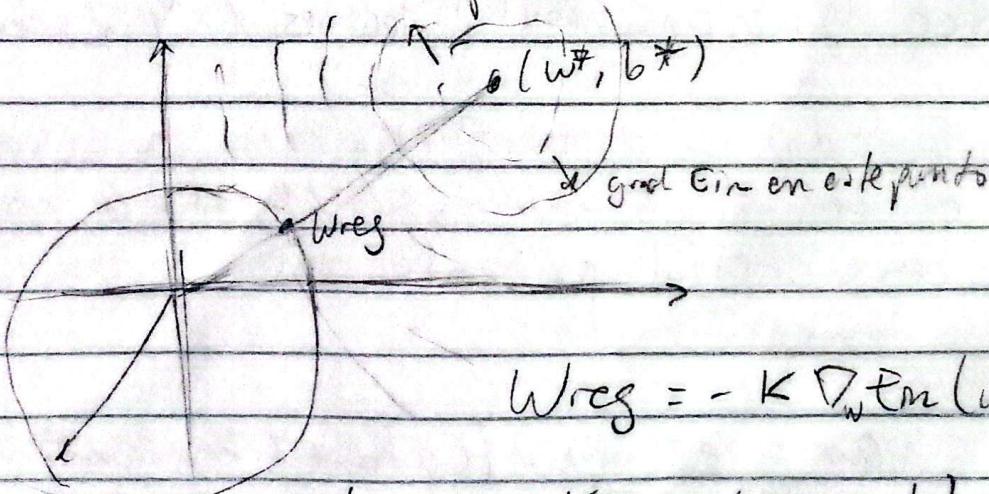
L₁ funciona mejor cuando las dimensiones

4 feb 2026

$$w^*, b^* = \arg \min_n E_{in}(w, b)$$

$$\begin{aligned} & \text{bajo } \sum_{j=1}^J w_j^* \leq C \\ & w^T w \leq C \\ & \|w\|_2^2 \leq C \end{aligned} \quad \left. \begin{array}{l} \text{Estos son los} \\ \text{mismos} \end{array} \right\}$$

$$w_1^2 + w_2^2 \leq \sqrt{C}^2$$



$$W_{reg} = -K \nabla E_{in}(w, b)$$

$$(W_{reg} + K \nabla E_{in}(W_{reg}, b)) = 0$$

También es positivo

$$2 \nabla W_{reg} + \nabla E_{in}(W_{reg}, b) = 0$$

$$D_w(Ein(w, b) + \lambda w^T w)$$

$$D_w \quad Ein(w, b) + \frac{1}{2} \lambda w^T w$$

Multiplicadores de La Grange

5 Feb 2026

Arboles de decision

$$f: X \rightarrow Y$$

y queremos ajustar $h(\theta): X \rightarrow Y$ a partir de un conjunto de datos $(X^{(1)}, Y^{(1)})$

	f_1	f_2	\dots	f_n	← feature
$X^{(1)}$	$x_1^{(1)}$	$x_2^{(1)}$	\dots	$x_n^{(1)}$	$y^{(1)}$
$X^{(2)}$	$x_1^{(2)}$	$x_2^{(2)}$	\dots	$x_n^{(2)}$	$y^{(2)}$
\vdots					
$X^{(n)}$	$x_1^{(n)}$	$x_2^{(n)}$	\dots	$x_n^{(n)}$	$y^{(n)}$

def generar_arbol(features, X, Y, nodo)

Si todos los datos pertenecen a misma clase, si no hay datos o si no hay características entonces regresa nodo;

var = escoge_feature(features, X, y)

separa los datos en las características

Quitar var de features

por valor en valores(var)

$X_h, Y_h = separa_datos(X, Y, var, val)$

$nh = \text{crear_hijo}(n, y_h)$

> Cuando no puede tomar decision que queden con
la clase del nodo(s)

$N_h = \text{generar_arbol}(\text{features}, X_n, Y_n, nh)$