

20 marzo 2026

¿Cómo es un proceso de decisión de Markov?

MDP.

$S \in S$

$a \in A$

$A_s: S \rightarrow S(A)$

$T: S \times A \times S \rightarrow \mathbb{R}$ tal que $T(s, a, s') = \mathbb{P}$
($\Pr(S_{t+1} = s' | S_t = s, A_t = a)$)

$r: S \times A \times S \rightarrow \mathbb{R}$ tal que $r(s, a, s')$ es la recompensa de ir de s a s' con la acción a

$S_T \subseteq S$ conjunto de estados terminales

$0 \leq \gamma \leq 1$ factor de descuento

¿Qué es lo que quiero? Quiero encontrar una política estocástica.

$\pi: S \times A \rightarrow \mathbb{R}$, $\pi(s, a) = \Pr(A_t = a | S_t = s)$

con qué probabilidad yo debería elegir la acción a

política tal que la esperanza siguiendo esa política sea máxima. Quiero maximizar mi retorno.

$E^\pi[R_T]$ sea máxima

$R_T = r_T + \gamma r_{T+1} + \gamma^2 r_{T+2} + \dots = r_T + \gamma R_{T+1}$

Debo tener una manera de evaluar cuando una política es mejor que otra

20 Marzo 2026

$$\text{SI } V^\pi(s) = E^\pi [R_T | S_T = s]$$

$$\pi_1 \leq \pi_2 \text{ si } V^{\pi_1}(s) \leq V^{\pi_2}(s) \forall s \in S$$

Tenemos que calcular $V^\pi(s)$

Yo se que donde empiezo y que voy a llegar usando la política.

$$V^\pi(s) = E^\pi [R_T | S_T = s]$$

↓

$$V^\pi(s) = \sum_{a \in A(s)} \pi(s, a) \sum_{s' \in S} T(s, a, s')$$

$$* [r(s, a, s') + \gamma V^\pi(s')]$$

Iter-política (mdp, política π , max-iter=1e3)

$$V = \{s: 0 \text{ for } s \text{ in mdp } S\}$$

for - in range(max-iter):

error relativo

$$\text{err} = 0$$

for s in mdp.S

$$vt = \text{sum}(\pi(s, a) * \text{sum}(\text{mdp.T}(s, a, s')$$

$$* [\text{mdp.r}(s, a, s') + \text{mdp} \cdot \gamma * V[s']$$

for s' in mdp.S

)

for a in mdp.a-legales(s)

$$\text{err} = \max(\text{err}, \text{abs}(vt - V[s]))$$

$$V[s] = vt$$

if err < tol:

break

return V

20 Marzo 2026

$$Q(s, a) = E^{\pi} [R_T \mid S_T = s, A_T = a]$$

$$Q^{\pi}(s, a) = \sum_{s' \in S} T(s, a, s') [r(s, a, s') + \gamma \sum_{a' \in A(s')} \pi(s', a') Q^{\pi}(s', a')]$$

$$V^{\pi}(s) = \sum_{a \in A(s)} \pi(s, a) Q(s, a)$$

Gracias a esto podemos determinar cual es la política óptima.

$\pi \leq \pi^* \quad \forall \pi \in \Pi$ si tengo una política mejor a la

π^* es la política óptima. Siempre existe al menos una política óptima.

Si tengo una política óptima puedo asumir que V^* y Q^* son las funciones de valor óptimas.

$$V^*(s) = V^{\pi^*}(s), \quad Q^*(s, a) = Q^{\pi^*}(s, a)$$

$$V^*(s) = \sum_{a \in A(s)} \pi(s, a) Q^*(s, a)$$

Ejemplo:

$$Q^*(s, a_1) = 5, \quad Q^*(s, a_2) = 7$$

$$V^*(s) = \pi(s, a_1) * 5 + \pi(s, a_2) * 7$$

$$V^*(s) = \pi(s, a_1) * 5 + \pi(s, a_2) * 7$$

$$V^*(s) = \max_{a \in A(s)} Q^*(s, a)$$

$$\pi(s, a) = \begin{cases} 1 & \text{si } a = \arg \max_{a' \in A(s)} Q^*(s, a') \\ 0 & \text{o.c.} \end{cases}$$

20 marzo 2026

$$Q^*(s, a) = \sum_{s' \in S} T(s, a, s') [r(s, a, s') + \gamma \max_{a' \in A(s')} Q^*(s', a')]$$

Ecuación de optimalidad de Bellman

23 marzo 2026

$$V^*(s) = \max_{a \in A(s)} Q^*(s, a)$$

> Algoritmo de iteración de valor Algoritmo básico de prog. lineal dinámica

def iter_valor (MDP, max_iter = 1e5, tol = 1e-6

$Q = \{ (s, a) : 0 \text{ for } s \text{ in MDP.estados} \\ \text{for } a \text{ in MDP.acciones-legales}(s) \}$

for - in range(max_iter):

error = 0

for (s, a) in Q.keys():

q = sum(MDP.T(s, a, s') * (MDP.r(s, a, s') + MDP.γ * max(Q[(s', a')] for a' in MDP.acciones-legales(s')) for s' in MDP.estados)

error = max(error, abs(Q[(s, a)] - q))

Q[(s, a)] = q

if err < tol:

break

return Q